BÁO CÁO BÀI THỰC HÀNH 01: THU THẬP VÀ THỐNG KÊ MÔ TẢ DỮ LIỆU

Môn học: Khai thác dữ liệu (DS102)

Lớp học phần: DS102.R11.CNVN.2

Học viên thực hiện: Đỗ Bá Luân

Mã số sinh viên: 23520895

---

1. TỔNG QUAN VÀ PHƯƠNG PHÁP THU THẬP DỮ LIỆU

1.1. Nguồn dữ liệu (Data Source)

- **Tên trang web:** Cửa hàng thương mại điện tử chính thức của nghệ sĩ Ariana Grande.
- **Tên miền gốc:** shop.arianagrande.com
- **Điểm cuối API truy xuất:** `https://shop.arianagrande.com/products.json?limit=250`
- **Lý do lựa chọn:** Cửa hàng sử dụng nền tảng Shopify với cấu trúc dữ liệu thương mại điện tử chuẩn hóa, cung cấp thông tin đa dạng về sản phẩm âm nhạc, thời trang (merchandise), ấn phẩm kỷ niệm và các gói combo người hâm mộ (fan packs/bundles).

1.2. Công cụ và Phương pháp trích xuất (Web Crawling)

- **Ngôn ngữ & Thư viện:** Python 3 (`requests`, `pandas`, `json`).
- **Quy trình cào dữ liệu (`crawler.py`):**

1. Gửi HTTP GET Request có gắn `User-Agent` hợp lệ đến API của cửa hàng.

2. Bóc tách dữ liệu JSON trả về, duyệt qua mảng danh sách `products`.

3. Với mỗi sản phẩm, trích xuất: tiêu đề (`title`), định danh đường dẫn (`handle`), danh mục phân loại (`product_type`), và truy xuất biến thể đầu tiên (`variants[0]`) để lấy đơn giá (`price`) và mã định danh lưu kho (`sku`).

4. Tạo đường dẫn chi tiết sản phẩm: `url = f"https://shop.arianagrande.com/products/{handle}"`.

5. Đóng gói dữ liệu vào DataFrame và xuất lưu đồng thời ra **3 định dạng chuẩn**:

- data.csv
- data.tsv
- data.json

---

2. BẢN ĐẶC TẢ CẤU TRÚC DỮ LIỆU (DATA SCHEMA)

Toàn bộ tập dữ liệu gồm **197 điểm dữ liệu** (sản phẩm), hoàn toàn vượt mức yêu cầu tối thiểu (100 mẫu) của đề bài.

Tên trường (Field)	Kiểu dữ liệu	Số lượng không rỗng	Tỷ lệ thiếu (Null %)	Ý nghĩa mô tả	Ví dụ thực tế
title	Text (String)	197 / 197	0.0%	Tên tiêu đề đầy đủ của mặt hàng	*petal core t-shirt (black)*
price	Numeric (Float)	197 / 197	0.0%	Giá bán niêm yết bằng đô la Mỹ ($ USD)	35.00
type	Categorical (String)	197 / 197	0.0%	Danh mục phân loại mặt hàng	T-Shirt, CD, 1LP
sku	Categorical / String	197 / 197	0.0%	Mã quản lý tồn kho duy nhất của sản phẩm	835463253

url	URL (String)	197 / 197	0.0%	Đường dẫn truy cập trực tiếp trang chi tiết	https://shop.arianagrande...

Nhận xét chất lượng: Bộ dữ liệu có độ hoàn thiện tuyệt đối (100% dữ liệu sạch, không chứa giá trị khuyết thiếu hay bất thường kiểu dữ liệu).

---

3. THỐNG KÊ MÔ TẢ VÀ PHÂN TÍCH ĐẶC TRƯNG CƠ BẢN

3.1. Phân tích biến định lượng: Giá bán sản phẩm (`price`)

Thuộc tính price là đại lượng đo lường giá trị kinh tế của từng sản phẩm. Bảng thống kê chi tiết theo 5 số tóm tắt (Five-number summary) như sau:

Chỉ số thống kê	Ký hiệu / Công thức	Giá trị ($ USD)	Ý nghĩa thực tế
Tổng số quan sát	*N*	197	100% sản phẩm có đơn giá xác định
Giá trung bình	*X(Mean)*	**$37.20**	Mức giá trung bình của toàn bộ cửa hàng
Độ lệch chuẩn	*σ(Std)*	**$27.35**	Mức độ phân tán giá tương đối rộng
Giá nhỏ nhất	*Min*	**$1.99**	Các đĩa đơn CD single dạng khuyến mãi

Phân vị 25%	*Q1*	**$14.00**	25% sản phẩm có giá dưới $14.00
Trung vị (Phân vị 50%)	*Median(Q2)*	**$35.00**	50% sản phẩm có giá từ $35.00 trở xuống
Phân vị 75%	*Q3*	**$45.99**	75% sản phẩm có giá dưới $45.99
Giá lớn nhất	*Max*	**$135.00**	Các combo kỷ niệm (Anniversary Bundle)
Khoảng biến thiên	*Range = Max - Min*	**$133.01**	Độ trải rộng giá trị
Khoảng tứ phân vị	*IQR = Q3 - Q1*	**$31.99**	Độ biến thiên 50% vùng trung tâm

Nhận xét hình dạng phân phối:

- Do *Mean(37.20) > Median (35.00)*, phân phối giá bị lệch phải nhẹ. Điều này hoàn toàn phù hợp với quy luật thương mại: đa phần sản phẩm tập trung ở phân khúc phổ thông ($10 - $45), trong khi một số ít sản phẩm đặc biệt (như box set, bundle kỷ niệm 10 năm) có giá cao ($100 - $135) kéo giá trị trung bình lên cao hơn.

3.2. Phân tích biến định tính: Danh mục sản phẩm (`type`)

Tập dữ liệu ghi nhận tổng cộng **27 loại sản phẩm** khác nhau. Bảng dưới đây thể hiện 10 nhóm sản phẩm chiếm tỷ trọng lớn nhất cửa hàng:

STT	Danh mục sản phẩm (type)	Số lượng	Tỷ lệ (%)	Giá TB ($)	Giá Min ($)	Giá Max ($)
1	**CD** (Đĩa nén âm nhạc)	28	14.21 %	$11.85	$1.99	$21.99
2	**Crewneck** (Áo chui đầu cổ tròn)	24	12.18 %	$68.96	$40.00	$85.00
3	**T-Shirt** (Áo thun)	20	10.15 %	$35.00	$35.00	$35.00
4	**Digital** (Album nhạc số)	20	10.15 %	$10.85	$7.99	$14.00
5	**1LP** (Đĩa than Vinyl 1 đĩa)	18	9.14 %	$36.27	$27.99	$49.99
6	**Other** (Vật phẩm khác)	12	6.09 %	$25.21	$10.00	$95.00
7	**Hoodie (pullover)** (Áo mũ trùm)	11	5.58 %	$80.00	$70.00	$100.00
8	**7in** (Đĩa than đĩa đơn 7 inch)	11	5.58 %	$14.72	$13.99	$14.99

9	**Women's T-Shirt** (Áo thun nữ)	8	4.06 %	$42.50	$35.00	$45.00
10	**Cassette** (Băng cát-xét)	7	3.55 %	$13.13	$6.99	$19.99
--	*17 danh mục còn lại (Bundle, Sweatpants, Hat...)*	38	19.31 %	--	--	--
Tổng	**27 danh mục**	**197**	**100.0 %**	**$37.20**	**$1.99**	**$135.00**

Nhận định cấu trúc giá theo danh mục:

1. Nhóm Âm nhạc truyền thống & Kỹ thuật số (Digital, CD, Cassette, 7in): Có mức giá dễ tiếp cận nhất ($1.99 - $21.99, giá trung bình khoảng $10 - $14).

2. Nhóm Thời trang thường nhật (T-Shirt, Dad Hat, 1LP Vinyl): Có mức giá tiêu chuẩn dao động cố định ở mức $35.00.

3. Nhóm Thời trang cao cấp (Crewneck, Sweatpants, Hoodie): Mức giá trung bình cao ($68 - $85).

4. Nhóm Gói sưu tầm đặc biệt (Bundle / Fan Pack): Giá trung bình lên tới $110.00 (cao nhất là $135.00).

3.3. Thống kê đặc trưng thuộc tính văn bản: Tiêu đề (`title`)

Phân tích độ dài ký tự và số từ trong tên tiêu đề sản phẩm:

- **Độ dài ký tự (`title_len`):** Trung bình là **32.32 ký tự** (ngắn nhất: 8 ký tự, dài nhất: 81 ký tự, trung vị: 29 ký tự).
- **Số từ (`word_count`):** Trung bình là **5.22 từ** (ít nhất: 2 từ, nhiều nhất: 12 từ, trung vị: 5 từ).